

Diseño e Implementación de una Arquitectura RAG Híbrida para la Modernización del Sistema de Consulta de los Diarios de Sesiones del Parlamento de Canarias: Un Análisis Técnico y Científico en el Marco del IATEXT-ULPGC

La preservación de la memoria democrática y la transparencia en la gestión pública encuentran en los Diarios de Sesiones del Parlamento de Canarias una de sus fuentes documentales más críticas. Estos registros no solo contienen la transcripción literal de la actividad legislativa, sino que representan un corpus lingüístico y sociopolítico de incalculable valor para investigadores y ciudadanos. En este contexto, el Instituto Universitario de Análisis y Aplicaciones Textuales (IATEXT) de la Universidad de Las Palmas de Gran Canaria (ULPGC) ha desempeñado un papel fundamental a través del desarrollo de herramientas de recuperación de información especializadas, como el buscador textual DiSeCan y el prototipo DiSe para el Congreso de los Diputados.¹ No obstante, la transición hacia modelos de interacción más naturales y precisos exige la superación de los sistemas basados puramente en palabras clave, proponiendo en su lugar una arquitectura de Generación Aumentada por Recuperación (RAG, por sus siglas en inglés) de naturaleza híbrida.

Esta propuesta técnica no solo se fundamenta en la capacidad de respuesta de los modelos de lenguaje de gran escala (LLM), sino en la integración profunda con bases de datos relacionales existentes, aprovechando la potencia de cálculo de infraestructuras locales (on-premise) para garantizar la soberanía de los datos y la precisión fáctica. A medida que la inteligencia artificial generativa se consolida en el dominio legal y administrativo, surge la necesidad de orquestar sistemas que mitiguen las alucinaciones mediante el anclaje en fuentes oficiales, permitiendo que el buscador del Parlamento de Canarias evolucione hacia un asistente inteligente capaz de razonar sobre la legislación y los debates históricos.³

Contextualización del Corpus Parlamentario y el Rol del IATEXT

El IATEXT ha liderado la investigación en lingüística computacional y análisis textual en el archipiélago, con un equipo de doctores e ingenieros especializados en el tratamiento de

textos parlamentarios. Proyectos previos han abordado la representación y emoción en el discurso parlamentario, utilizando tecnologías para indexar legislaturas, oradores y temas específicos.¹ El corpus actual del Parlamento de Canarias, disponible a través de plataformas como Jable, abarca desde julio de 1987 hasta la actualidad, sumando más de 1.130 ejemplares y superando las 71.000 páginas de transcripciones.⁶ Esta densidad documental presenta desafíos significativos para la recuperación tradicional, donde la búsqueda de términos aislados puede ignorar el contexto semántico o la intención de las intervenciones.

La implementación de un sistema RAG en este entorno requiere una comprensión profunda de la estructura de los Diarios de Sesiones. Estos documentos combinan diálogos multi-orador con un lenguaje administrativo formal y, a menudo, referencias cruzadas a leyes o mociones anteriores.⁷ El IATEXT, bajo la dirección de investigadores como Gracia Piñero Piñero y Francisco Javier Carreras Riudavets, ha establecido las bases metodológicas para la estructuración de estos datos, lo que facilita su transición hacia arquitecturas neuronales de recuperación.¹

Fundamentos de la Arquitectura RAG Híbrida

La idea de montar un sistema RAG híbrido implica la coexistencia y sinergia de dos paradigmas de búsqueda: la búsqueda por palabras clave o atributos (típicamente gestionada por bases de datos relacionales como PostgreSQL o MariaDB) y la búsqueda semántica basada en vectores de alta dimensionalidad (embeddings).⁹ Este enfoque es particularmente valioso en el sector público, donde las consultas suelen requerir un filtrado preciso por metadatos (por ejemplo, "buscar intervenciones de un diputado específico en la legislatura X") combinado con una necesidad de comprensión conceptual.¹¹

El Reto de la Integración SQL-Vector

Las bases de datos relacionales son excelentes para manejar datos estructurados y filtros booleanos deterministas. Por otro lado, las bases de datos vectoriales permiten encontrar información basándose en el significado, incluso si las palabras exactas no coinciden. Un sistema híbrido orquestado adecuadamente permite que el usuario formule una pregunta en lenguaje natural, la cual se descompone en:

1. **Filtros de Metadatos:** Traducidos a consultas SQL para delimitar el espacio de búsqueda (fecha, orador, tipo de sesión).
2. **Búsqueda Semántica:** Ejecutada sobre el subconjunto de datos filtrados para encontrar los fragmentos de texto más relevantes.¹¹

La literatura reciente en el campo de la inteligencia artificial empresarial ha propuesto modelos como el **CSR-RAG** (Contextual, Structural, and Relational RAG), diseñado específicamente para bases de datos a escala de producción. Este sistema simultanea la búsqueda contextual con la exploración de la estructura del esquema de la base de datos y sus relaciones internas, logrando precisiones del 40% y recuperaciones (recall) superiores al 80% en entornos complejos.¹³ Para el IATEXT, esto significaría no solo recuperar texto, sino también entender cómo se vinculan las tablas de oradores, sesiones y leyes dentro del sistema existente.

Componente	Rol en el Sistema Híbrido	Ventaja Técnica
Almacenamiento Relacional (SQL)	Gestión de metadatos y consistencia de datos.	Precisión absoluta en filtrado booleano.
Almacenamiento Vectorial	Indexación de embeddings de fragmentos de texto.	Captura de matices semánticos y sinónimos.
Capa de Orquestación	Traducción de lenguaje natural a SQL/Vector.	Interfaz amigable para el usuario final.
Modelo de Re-ranking	Ordenación de los resultados recuperados.	Mejora la relevancia del contexto final. ¹⁵

Modelado Lingüístico y Recursos para el Español Legal

Uno de los pilares críticos para el éxito de un sistema RAG en el Parlamento de Canarias es el uso de modelos de lenguaje pre-entrenados en el dominio específico. El lenguaje jurídico y parlamentario en español posee una terminología y sintaxis propias que difieren notablemente del lenguaje general.¹⁶ La iniciativa PlanTL ha sido fundamental en la creación de recursos como **RoBERTalex**, un modelo de lenguaje basado en RoBERTa entrenado exclusivamente en un corpus legal español de 8,9 GB, que incluye legislación del BOE, dictámenes y sentencias.¹⁷

El Impacto de los Embeddings Especializados

Investigaciones publicadas en 2024 y 2025 demuestran que el uso de embeddings especializados como los de PlanTL supera significativamente a los modelos generales en tareas de recuperación de información legal. El estudio del proyecto Lynx, por ejemplo, destaca que la combinación de modelos como RoBERTalex con técnicas de expansión de consultas (Query Expansion) mediante terminologías controladas mejora el rendimiento de sistemas RAG aplicados al derecho laboral y administrativo.¹⁶

Para el buscador del IATEXT, esto implica que los fragmentos de los Diarios de Sesiones deben ser vectorizados utilizando modelos que comprendan conceptos como "proposición no de ley", "enmienda a la totalidad" o "comisión permanente". El uso de modelos como roberta-base-bne o RoBERTalex garantiza que la representación numérica del texto sea fiel a la jerarquía y matices del ámbito parlamentario.¹⁶

Fuente de Datos de Entrenamiento (RoBERTalex)	Tamaño (GB)	Tokens (M)
Legislación BOE	3.600	578.685
Spanish MultiUN	2.200	352.653
Consejo de Estado (Dictámenes)	0.827	135.348
Spanish DOGC	0.826	132.569

Además de los modelos de embedding, la elección del modelo generativo (LLM) es vital. Modelos como Mistral-7B, Llama 3.1 y Granite 3 han mostrado un rendimiento excepcional en

tareas de síntesis de respuestas a partir de documentos recuperados, especialmente cuando se despliegan en infraestructuras potentes que permiten el uso de versiones sin cuantizar o con cuantización mínima para preservar la capacidad de razonamiento.¹⁶

Optimización de la Infraestructura Local: vLLM y vRAM

La disponibilidad de una máquina potente permite al IATEX implementar un servidor de inferencia de alta eficiencia utilizando **vLLM**. Esta biblioteca de código abierto es capaz de servir modelos de lenguaje entre 10 y 24 veces más rápido que las implementaciones estándar de Hugging Face mediante innovaciones como **PagedAttention** y el batcheo continuo (continuous batching).²¹

Gestión Eficiente de Memoria

PagedAttention soluciona el problema del desperdicio de memoria en el caché de claves y valores (KV-cache), que en implementaciones tradicionales puede alcanzar el 60-80%. Al gestionar los bloques de atención de forma no contigua, vLLM permite procesar más solicitudes simultáneas y manejar contextos más largos, algo esencial cuando se analizan intervenciones parlamentarias extensas.²¹

Para un modelo de 70 mil millones de parámetros como Llama 3.1, los requisitos de vRAM son considerables:

- **Precisión FP16 (Completa):** Requiere aproximadamente 144 GB de VRAM. Esto se puede lograr con configuraciones multi-GPU (por ejemplo, 2x A100 de 80 GB).²⁴
- **Cuantización INT4/AWQ:** Reduce el requerimiento a unos 48 GB de VRAM, manteniendo un rendimiento muy alto y una degradación mínima de la precisión.²¹

Considerando que el IATEX dispone de hardware potente, el uso de técnicas como el paralelismo de tensores (Tensor Parallelism) permite dividir el modelo entre varias GPUs para optimizar la latencia y el rendimiento.²² Esto es fundamental para garantizar que el buscador responda en milisegundos incluso bajo cargas de usuarios concurrentes.

El Paradigma de Table-Augmented Generation (TAG)

Un desarrollo puntero para 2025 es el concepto de **Table-Augmented Generation (TAG)**, propuesto por investigadores de Stanford y Berkeley. El TAG aborda una limitación crítica del Text-to-SQL y del RAG convencional: la incapacidad de razonar semánticamente sobre grandes volúmenes de datos tabulares.²⁷

En el buscador de Diarios de Sesiones, muchas preguntas no pueden responderse con un simple fragmento de texto. Consultas como "¿Cuál ha sido la evolución del gasto presupuestario mencionado en sanidad por diferentes partidos?" requieren que el sistema extraiga datos de múltiples registros, realice comparaciones y sintetice una tendencia. El sistema TAG unifica esto en tres pasos:

1. **Síntesis de Consulta:** Traduce la petición a una consulta ejecutable enriquecida con

funciones de LLM.

2. **Ejecución de Consulta:** El motor de la base de datos procesa el volumen de datos.
3. **Generación de Respuesta:** El LLM utiliza la tabla resultante para generar la respuesta final.²⁷

La implementación de este paradigma sobre el framework **LOTUS** permitiría al IATEXT realizar filtros semánticos complejos (por ejemplo, identificar intervenciones "positivas" o "críticas" sobre un tema de forma agregada) que serían imposibles con SQL tradicional o RAG básico.²⁹

Estrategias de Segmentación y Procesamiento de Documentos

La calidad de las respuestas en un sistema RAG depende intrínsecamente de cómo se fragmenten (chunking) los Diarios de Sesiones. Dado que se trata de documentos con una estructura clara (puntos del día, turnos de palabra, interrupciones), la segmentación ciega por número de palabras es contraproducente.³⁰

Técnicas de Fragmentación Avanzadas

Se recomienda el uso de **fragmentación recursiva** que respete los límites de las intervenciones. Cada fragmento debe conservar metadatos críticos adjuntos para que el LLM pueda identificar siempre quién está hablando y en qué contexto.⁸

1. **Fragmentación Semántica:** Utiliza cambios en la similitud de los embeddings para detectar transiciones de temas dentro de una misma intervención larga.³²
2. **Fragmentación Jerárquica:** Mantiene resúmenes de "nivel superior" para orientar la búsqueda y fragmentos "granulares" para la recuperación precisa de hechos. Esto permite que el sistema responda tanto a preguntas generales sobre una sesión como a detalles específicos.³⁰
3. **Fragmentación Basada en Agentes:** Una técnica experimental donde un modelo de lenguaje decide dónde cortar el texto basándose en la coherencia lógica y la estructura del discurso parlamentario.³⁰

La incorporación de un solapamiento (overlap) de aproximadamente el 10-20% entre fragmentos asegura que el contexto no se pierda en los puntos de corte, permitiendo que oraciones que cruzan los límites de un segmento sigan siendo comprensibles.³⁴

Evaluación de la Veracidad y Mitigación de Alucinaciones

En un entorno institucional como el Parlamento de Canarias, la veracidad es la métrica de éxito definitiva. Los sistemas RAG deben ser evaluados mediante marcos que midan la **Fidelidad (Faithfulness)** y la **Relevancia del Contexto**.³⁶

Métricas y Benchmarks

El uso de **RAGAS** y **DeepEval** permite automatizar la evaluación utilizando el enfoque de "LLM

como juez" (LLM-as-a-judge). Estas herramientas descomponen la respuesta del sistema en afirmaciones individuales y verifican cada una de ellas contra el texto original recuperado.³⁶

Métrica	Definición	Objetivo
Faithfulness	Ratio de afirmaciones respaldadas por el contexto.	Eliminar alucinaciones.
Context Relevancy	Grado de utilidad de los fragmentos recuperados.	Optimizar el recuperador (Retriever).
Answer Relevancy	Pertinencia de la respuesta a la consulta original.	Evaluar la calidad de la síntesis del LLM.
Context Recall	Proporción de información relevante recuperada.	Minimizar omisiones críticas. ³⁶

Para alcanzar un nivel de confianza del 90% o superior, es necesario implementar ciclos de validación humana (human-in-the-loop) donde expertos lingüistas del IATEXT validen un conjunto de preguntas y respuestas de "oro" (Gold Standard). Este conjunto sirve para ajustar los hiperparámetros del sistema, como el tamaño de los fragmentos, el modelo de embedding y el prompt del generador.³⁶

Implementación Técnica y Flujo de Trabajo

El desarrollo del sistema para el Parlamento de Canarias debería seguir una metodología modular que integre el pre-procesamiento de datos con la inferencia en tiempo real.

Paso 1: Ingesta y Estructuración de Datos

Utilizando herramientas como **Unstructured.io**, se pueden automatizar la extracción de metadatos de los PDFs de los Diarios de Sesiones, identificando tablas, encabezados y oradores de forma consistente.¹¹ Esta información se carga en la base de datos relacional y se vincula con los vectores en el almacén vectorial.

Paso 2: Pipeline de Recuperación Híbrida

Se implementa una lógica de consulta que primero analice la intención del usuario. Si la consulta incluye entidades temporales o nombres propios, se activa un filtro SQL. Si es puramente temática, se prioriza la búsqueda vectorial. Los resultados de ambos se fusionan mediante técnicas de **Reciprocal Rank Fusion (RRF)** para equilibrar la precisión y la cobertura.⁹

Paso 3: Generación con Anclaje (Grounded Generation)

El prompt enviado al LLM (Llama 3.1 o similar) debe ser estructurado siguiendo las mejores prácticas de ingeniería de instrucciones. Se debe indicar explícitamente al modelo: "Responde únicamente basándote en el contexto proporcionado. Si la información no está presente, indica que no se dispone de datos oficiales".³⁷ La inclusión de citas directas es fundamental para la transparencia.¹⁰

Paso 4: Monitoreo y Ajuste

Dada la naturaleza dinámica de la actividad parlamentaria, el sistema debe permitir actualizaciones frecuentes sin necesidad de re-entrenar los modelos. La arquitectura RAG facilita esto, ya que solo requiere indexar los nuevos documentos a medida que se publican.⁴

Consideraciones sobre la Soberanía de Datos y la Ética Pública

La decisión de realizar una implementación on-premise no es meramente técnica, sino ética y estratégica. El Reglamento Europeo de Inteligencia Artificial impone requisitos estrictos de transparencia y gobernanza para los sistemas utilizados en el sector público.⁴³ Mantener la infraestructura bajo el control de la ULPGC garantiza:

1. **Protección de Datos:** Se evita que datos potencialmente sensibles de ciudadanos o parlamentarios salgan del control institucional hacia nubes de terceros.¹⁰
2. **Auditoría y Trazabilidad:** Cada respuesta puede ser auditada, permitiendo identificar exactamente qué fragmento de qué diario de sesiones dio origen a una afirmación.¹⁰
3. **Reducción de Sesgos:** El uso de modelos especializados como RoBERTalex, entrenados en datos oficiales españoles, reduce el sesgo cultural y lingüístico presente en modelos entrenados mayoritariamente con contenido en inglés o de internet generalista.¹⁸

La implementación de este sistema se alinea con las estrategias regionales de digitalización y sostenibilidad del Gobierno de Canarias, promoviendo la interdisciplinariedad y la transferencia tecnológica desde la universidad hacia la administración pública.⁴⁵

Perspectiva de Futuro: De la Búsqueda a la Inteligencia Parlamentaria

El horizonte de esta investigación apunta hacia sistemas aún más avanzados, como el **Agentic RAG**, donde la IA no solo busca información, sino que utiliza herramientas externas (como bases de datos de leyes o registros estadísticos) para validar y ampliar sus respuestas.³⁰ En el contexto canario, esto podría permitir la comparación automática entre legislaciones de diferentes comunidades autónomas o el análisis temporal de la efectividad de las mociones parlamentarias.

La infraestructura propuesta, combinando el rigor del IATEX en el análisis textual con la potencia de los sistemas RAG híbridos y el despliegue optimizado con vLLM, posiciona al buscador del Parlamento de Canarias como una referencia internacional en informática parlamentaria. La capacidad de interactuar con décadas de debate democrático mediante lenguaje natural, con garantías de veracidad y precisión, democratiza el acceso a la información y fortalece el tejido institucional del archipiélago.

Para concluir, el camino hacia un sistema RAG híbrido efectivo requiere un compromiso entre la tecnología de vanguardia y el conocimiento experto del dominio. Los resultados obtenidos con modelos como RoBERTalex y arquitecturas como CSR-RAG demuestran que es posible

alcanzar niveles de precisión cercanos a la consulta experta humana, siempre que se respete la integridad de los datos y se mantenga una evaluación rigurosa y transparente.¹³ El IATEX ULPGC tiene ante sí la oportunidad de transformar el acceso a la historia legislativa de Canarias, convirtiendo archivos estáticos en conocimiento dinámico y accionable para la sociedad del siglo XXI.

Obras citadas

1. DiSe Diario de Sesiones, fecha de acceso: febrero 18, 2026, <https://dise.iatext.ulpgc.es/congreso/>
2. Aplicaciones de Humanidades Digitales: Buscadores con ..., fecha de acceso: febrero 18, 2026, <https://iatext.ulpgc.es/es/aplicaciones/buscador-textual>
3. Retrieval-Augmented Generation with Vector Stores, Knowledge Graphs, and Hierarchical Non-negative Matrix Factorization - arXiv, fecha de acceso: febrero 18, 2026, <https://arxiv.org/html/2502.20364v1>
4. What is Retrieval Augmented Generation (RAG)? - Databricks, fecha de acceso: febrero 18, 2026, <https://www.databricks.com/glossary/retrieval-augmented-generation-rag>
5. Implementación de técnicas de RAG (Retrieval Augmented Generation) sobre LLM (Large Language Models) para la extracción y generación de documentos en las entidades públicas - UVaDOC Principal, fecha de acceso: febrero 18, 2026, <https://uvadoc.uva.es/handle/10324/71509>
6. Diario de sesiones del Parlamento de Canarias - Jable, fecha de acceso: febrero 18, 2026, <https://jable.ulpgc.es/diariospc>
7. NLP for Local Governance Meeting Records: A Focus Article on Tasks, Datasets, Metrics and Benchmarks - arXiv, fecha de acceso: febrero 18, 2026, <https://arxiv.org/html/2602.08162v1>
8. Chunking Strategies for Complex RAG Documents (Financial + Legal) - Reddit, fecha de acceso: febrero 18, 2026, https://www.reddit.com/r/Rag/comments/1nf8e1b/chunking_strategies_for_complex_rag_documents/
9. Hybrid RAG in the Real World: Graphs, BM25, and the End of Black-Box Retrieval, fecha de acceso: febrero 18, 2026, <https://community.netapp.com/t5/Tech-ONTAP-Blogs/Hybrid-RAG-in-the-Real-World-Graphs-BM25-and-the-End-of-Black-Box-Retrieval/ba-p/464834>
10. Hybrid RAG Architecture: Bridging Structured and Unstructured Data for Smarter AI, fecha de acceso: febrero 18, 2026, <https://www.techaheadcorp.com/blog/hybrid-rag-architecture-definition-benefits-use-cases/>
11. Metadata for RAG: Improve Contextual Retrieval | Unstructured, fecha de acceso: febrero 18, 2026, <https://unstructured.io/insights/how-to-use-metadata-in-rag-for-better-contextual-results>
12. Metadata-Based Filtering in RAG Systems | CodeSignal Learn, fecha de acceso: febrero 18, 2026,

- <https://codesignal.com/learn/courses/scaling-up-rag-with-vector-databases-in-rust/lessons/metadata-based-filtering-in-rag-systems-with-rust-and-qdrant>
13. CSR-RAG: An Efficient Retrieval System for Text-to-SQL on the Enterprise Scale - arXiv, fecha de acceso: febrero 18, 2026, <https://arxiv.org/html/2601.06564v1>
 14. CSR-RAG: An Efficient Retrieval System for Text-to-SQL on the Enterprise Scale, fecha de acceso: febrero 18, 2026, https://www.researchgate.net/publication/399707332_CSR-RAG_An_Efficient_Retrieval_System_for_Text-to-SQL_on_the_Enterprise_Scale
 15. A Survey of Graph Retrieval-Augmented Generation for Customized Large Language Models - arXiv, fecha de acceso: febrero 18, 2026, <https://arxiv.org/html/2501.13958v1>
 16. Terminology Enhanced Retrieval Augmented Generation for Spanish Legal Corpora - ACL Anthology, fecha de acceso: febrero 18, 2026, <https://aclanthology.org/2025.ltk-1.16.pdf>
 17. RoBERTalex · Models - Dataloop, fecha de acceso: febrero 18, 2026, https://dataloop.ai/library/model/plantl-gob-es_robertalex/
 18. PlanTL-GOB-ES/lm-legal-es: Language Models for the ... - GitHub, fecha de acceso: febrero 18, 2026, <https://github.com/PlanTL-GOB-ES/lm-legal-es>
 19. Framing Migration: A Computational Analysis of UK Parliamentary Discourse - arXiv, fecha de acceso: febrero 18, 2026, <https://arxiv.org/html/2509.14197v1>
 20. Understanding Llama: Technical foundations and applications - DataNorth AI, fecha de acceso: febrero 18, 2026, <https://datanorth.ai/blog/understanding-llama-technical-foundations-and-applications>
 21. How to Deploy LLMs with vLLM for High-Performance Inference, fecha de acceso: febrero 18, 2026, <https://oneuptime.com/blog/post/2026-01-27-vllm-llm-deployment/view>
 22. Why vLLM is the best choice for AI inference today - Red Hat Developer, fecha de acceso: febrero 18, 2026, <https://developers.redhat.com/articles/2025/10/30/why-vllm-best-choice-ai-inference-today>
 23. Ollama vs vLLM: A Comprehensive Guide to Local LLM Serving | by Mustafa Genc - Medium, fecha de acceso: febrero 18, 2026, <https://medium.com/@mustafa.genc94/ollama-vs-vllm-a-comprehensive-guide-to-local-llm-serving-91705ec50c1d>
 24. Serving LLMs with vLLM: A practical inference guide - Nebius, fecha de acceso: febrero 18, 2026, <https://nebius.com/blog/posts/serving-llms-with-vllm-practical-guide>
 25. Run Llama 3 on Dell PowerEdge XE9680 and AMD MI300x with vLLM, fecha de acceso: febrero 18, 2026, <https://infohub.delltechnologies.com/p/run-llama-3-on-dell-powerededge-xe9680-and-amd-mi300x-with-vllm/>
 26. 10 Best Open-Source LLMs 2026: Llama 3.1, Gemma 2 & Command R+ - Vertu, fecha de acceso: febrero 18, 2026, <https://vertu.com/lifestyle/top-10-open-source-llms-for-2025-a-deep-dive-into->

[the-future-of-ai/](#)

27. Text2SQL is Not Enough: Unifying AI and Databases with TAG, fecha de acceso: febrero 18, 2026, <https://vldb.org/cidrdb/papers/2025/p11-biswal.pdf>
28. What is Table-Augmented Generation (TAG)? A Practical Guide - K2view, fecha de acceso: febrero 18, 2026, <https://www.k2view.com/what-is-table-augmented-generation>
29. Why Text2SQL Alone Isn't Enough: Embracing TAG - DZone, fecha de acceso: febrero 18, 2026, <https://dzone.com/articles/why-text2sql-alone-isnt-enough-embracing-tag>
30. Chunking Strategies to Improve LLM RAG Pipeline Performance - Weaviate, fecha de acceso: febrero 18, 2026, <https://weaviate.io/blog/chunking-strategies-for-rag>
31. Develop a RAG Solution - Chunking Phase - Azure Architecture Center | Microsoft Learn, fecha de acceso: febrero 18, 2026, <https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/rag/rag-chunking-phase>
32. Implement RAG chunking strategies with LangChain and watsonx.ai - IBM, fecha de acceso: febrero 18, 2026, <https://www.ibm.com/think/tutorials/chunking-strategies-for-rag-with-langchain-watsonx-ai>
33. Chunking Strategies for RAG - Breaking Down Documents for Better Retrieval | Sifal Klioui, fecha de acceso: febrero 18, 2026, <https://sifal.social/posts/Chunking-Strategies-for-RAG-Breaking-Down-Documents-for-Better-Retrieval/>
34. Comparing the Performance of LLMs in RAG-based Question-Answering: A Case Study in Computer Science Literature - arXiv, fecha de acceso: febrero 18, 2026, <https://arxiv.org/html/2511.03261v1>
35. LLM RAG Tutorial: Examples and Best Practices | LaunchDarkly, fecha de acceso: febrero 18, 2026, <https://launchdarkly.com/blog/llm-rag-tutorial/>
36. RAG Evaluation Metrics: Best Practices for Evaluating RAG Systems, fecha de acceso: febrero 18, 2026, <https://www.patronus.ai/llm-testing/rag-evaluation-metrics>
37. RAG Evaluation Metrics: Assessing Answer Relevancy, Faithfulness, Contextual Relevancy, And More - Confident AI, fecha de acceso: febrero 18, 2026, <https://www.confident-ai.com/blog/rag-evaluation-metrics-answer-relevancy-faithfulness-and-more>
38. Faithfulness | DeepEval by Confident AI - The LLM Evaluation Framework, fecha de acceso: febrero 18, 2026, <https://deepeval.com/docs/metrics-faithfulness>
39. ARGUS: Retrieval-Augmented QA System for Government Services - MDPI, fecha de acceso: febrero 18, 2026, <https://www.mdpi.com/2079-9292/14/12/2445>
40. RAG Evaluation Metrics: Answer Relevancy, Faithfulness, and Real-World Accuracy, fecha de acceso: febrero 18, 2026, <https://www.deepchecks.com/rag-evaluation-metrics-answer-relevancy-faithfulness-accuracy/>
41. A complete guide to RAG evaluation: metrics, testing and best practices - Evidently AI, fecha de acceso: febrero 18, 2026,

<https://www.evidentlyai.com/llm-guide/rag-evaluation>

42. Framework de Evaluación para el patrón RAG implementado en Justicio - Medium, fecha de acceso: febrero 18, 2026, <https://medium.com/@bukosabino/framework-de-evaluaci%C3%B3n-para-el-patr%C3%B3n-rag-implementado-en-justicio-d8ca06bee17f>
43. El Parlamento de Canarias impulsa la formación en Inteligencia Artificial y ética para su aplicación institucional, fecha de acceso: febrero 18, 2026, https://www.parcn.es/noticias/detalle.py?ID_NOTICIA=3329
44. Evaluating the Limits of Large Language Models in Multilingual Legal Reasoning - arXiv, fecha de acceso: febrero 18, 2026, <https://arxiv.org/html/2509.22472v1>
45. Estrategia de Especialización Inteligente de Canarias - YouTube, fecha de acceso: febrero 18, 2026, <https://www.youtube.com/watch?v=h2fQ5P3hN2s>