

Integración Arquitectónica Híbrida Text-to-SQL y RAG para el Análisis del Discurso Político: Metodología Aplicada al Buscador Lingüístico DISECAN

Introducción a la Intersección entre Lingüística Computacional y Generación Aumentada en Humanidades Digitales

La evolución sin precedentes de los Modelos de Lenguaje de Gran Escala (LLM) ha transformado radicalmente los paradigmas de procesamiento de datos, recuperación de información y análisis textual en múltiples disciplinas, incidiendo de manera particularmente profunda en el ámbito de las Humanidades Digitales y el análisis del discurso político.¹ Históricamente, la lingüística de corpus ha dependido de herramientas de recuperación de información basadas en la concordancia exacta, la lematización y el análisis morfosintáctico riguroso para desentrañar las estructuras subyacentes en el lenguaje institucional y político.³ Estas metodologías clásicas permiten a los investigadores certificar la presencia de patrones discursivos mediante evidencias empíricas innegables. Sin embargo, la irrupción de las arquitecturas de Generación Aumentada por Recuperación (RAG, por sus siglas en inglés) ha desplazado progresivamente el foco de la comunidad científica hacia la búsqueda semántica mediante representaciones vectoriales densas.⁴

Aunque este nuevo paradigma vectorial sobresale en la identificación de similitudes conceptuales y en la comprensión del significado subyacente de los textos, la literatura académica contemporánea subraya que presenta deficiencias críticas y limitaciones operativas cuando se enfrenta a consultas que exigen una precisión léxico-estructural quirúrgica, o a la resolución de preguntas agregativas sobre vastos conjuntos documentales.⁶ La dependencia exclusiva de algoritmos de recuperación dispersa tradicional como BM25, o de métricas de distancia cosenoidal en espacios latentes, sacrifica el determinismo gramatical en favor de una fluidez que, a menudo, resulta insuficiente para el rigor requerido en el análisis sociopolítico o en la auditoría periodística.⁴

El presente análisis de investigación explora exhaustivamente el diseño, la fundamentación teórica y la viabilidad técnica de una arquitectura híbrida avanzada que integra las capacidades generativas y de comprensión semántica de los LLM con la precisión determinista de un motor de búsqueda lingüística relacional. El estudio toma como objeto central de integración el buscador DISECAN (Buscador con Inteligencia Lingüística en el Diario de Sesiones del Parlamento de Canarias), desarrollado por el Instituto Universitario de Análisis y Aplicaciones

Textuales (L^AT_EX) de la Universidad de Las Palmas de Gran Canaria (ULPGC).⁹ DISECAN, impulsado por la tecnología propietaria IntelLiText, constituye un paradigma excepcional de indexación léxica estructurada que opera mediante consultas SQL a una base de datos relacional y accesos posicionales físicos exactos a nivel de *byte*.¹¹

El objetivo central de esta investigación radica en articular una propuesta metodológica integral para un Trabajo de Fin de Título (TFT) orientada a trascender la dispersión y la inexactitud intrínseca de los sistemas RAG tradicionales.¹³ Se propone el diseño e implementación de un sistema "Hybrid-S-RAG" (Hybrid Structured RAG) que fusione el control absoluto sobre las categorías gramaticales, las combinaciones léxicas y las distancias posicionales que proporciona la lógica relacional SQL, con la inmensa capacidad de síntesis, razonamiento lógico y contextualización narrativa del modelo RAG.⁵

La convergencia de una infraestructura Text-to-SQL con el paradigma RAG no solo promete resolver el problema histórico de la recuperación episódica y agregativa en colecciones documentales extensas⁴, sino que establece un nuevo estándar de trazabilidad, auditabilidad y verificabilidad documental. Estos elementos son imperativos innegociables en el rigor ético y metodológico de la archivística, las ciencias sociales y el periodismo de datos.⁸ Al dotar a un modelo de lenguaje de la capacidad de operar una base de datos estructurada mediante sentencias SQL formalizadas antes de generar una respuesta natural, se mitigan sustancialmente las denominadas alucinaciones algorítmicas, garantizando de este modo que el discurso generado esté intrínseco y biunívocamente anclado en la evidencia textual original y en los metadatos institucionales.¹⁵

Arquitectura Fundamental de DISECAN y la Tecnología IntelLiText

Para comprender en su totalidad la viabilidad, los requisitos técnicos y los inmensos desafíos de integrar el sistema DISECAN en un entorno RAG contemporáneo, resulta absolutamente imperativo deconstruir su arquitectura subyacente y comprender las decisiones de diseño que lo sustentan. DISECAN no opera bajo el esquema simplificado de una base de datos NoSQL de documentos, ni utiliza un índice invertido convencional como los empleados por motores de búsqueda genéricos. Por el contrario, emplea un diseño altamente optimizado, bifurcado y determinista que separa deliberadamente los metadatos relacionales y las propiedades lingüísticas pre-calculadas del texto físico, maximizando con ello la velocidad de respuesta en consultas de extrema complejidad gramatical.¹²

El buscador fue conceptualizado y desarrollado en el marco del proyecto de investigación "Ultraperiferia y cohesión europea: conceptualización metafórica de Europa en el discurso político canario", bajo la dirección y participación de destacados investigadores del IATEX como Gracia Piñero Piñero, Francisco J. Carreras Riudavets y Zenón Hernández Figueroa, contando con el soporte de fondos competitivos del Gobierno de Canarias.¹⁰ Su núcleo tecnológico, denominado IntelLiText (Digitalización y motor de búsqueda inteligente), facilita la recuperación de información mediante inteligencia lingüística, permitiendo operaciones analíticas que exceden con creces la mera coincidencia de cadenas de caracteres.¹¹ Esta

tecnología otorga a los investigadores la capacidad de ejecutar búsquedas exactas considerando el orden secuencial, búsquedas abstractas por lema o raíz léxica, búsquedas categóricas por categoría gramatical (Part of Speech - POS), emplear comodines de truncamiento (como el asterisco para secuencias variables) e, incluso, definir una distancia posicional máxima —medida estrictamente en número de palabras— entre múltiples términos o estructuras sintácticas.¹⁰

La infraestructura técnica que soporta estas sofisticadas capacidades de interrogación se fundamenta en una base de datos relacional MySQL que alcanza un tamaño total aproximado de 5.6 Gigabytes, incluyendo sus intrincados índices de optimización.¹² La genialidad de su arquitectura de almacenamiento reside en su división estratégica: emplea tres tablas principales para gestionar los metadatos institucionales y las propiedades léxicas atomizadas, vinculándolas dinámicamente con dos archivos de texto plano masivos que contienen el corpus documental real y continuo.¹²

Componente Arquitectónico	Descripción Técnica y Función dentro del Sistema DISECAN	Volumen y Tamaño Físico Estimado
Tabla Relacional: Sessions	Almacena identificadores numéricos únicos (IDSession) y los metadatos fundamentales de los diarios de sesiones, incluyendo la fecha exacta de la intervención, el nombre del orador parlamentario y el tema de discusión tipificado.	Integrado en la Base de Datos MySQL de 5.6 GB
Archivo de Texto: sentences.txt	Fichero plano que contiene el texto segmentado de las oraciones. Cada línea posee un ID numérico (IDSentence), el texto de la oración, el <i>byte</i> de inicio exacto y el tamaño en <i>bytes</i> del párrafo contenedor en el archivo principal.	1.522.716 oraciones registradas (292.679 KB)
Archivo de Texto: paragraphs.txt	Fichero plano masivo que contiene el texto íntegro de los párrafos originales en su	336.787 párrafos continuos (257.842 KB)

	formato prístino. Es accedido de manera directa y no secuencial mediante el desfase de <i>bytes</i> referenciado en la tabla y en el archivo de oraciones.	
--	--	--

La separación radical entre la base de datos relacional y los archivos de texto plano constituye una decisión de ingeniería de software crítica para el rendimiento en tiempo real. El sistema elude deliberadamente el acceso secuencial al texto completo durante la fase de evaluación de la consulta; en su lugar, utiliza el mecanismo de *byte offset* (desplazamiento exacto de *bytes*) almacenado en la base de datos para ejecutar un salto directo a la posición de memoria física precisa en los archivos .txt y extraer el párrafo exacto.¹² Esta mecánica de bajo nivel evita la saturación y sobrecarga de la memoria RAM del servidor y suprime por completo los cuellos de botella de rendimiento tradicionalmente asociados a la recuperación masiva de campos de texto extenso (BLOB o TEXT) en bases de datos relacionales estándar.¹²

Esta particularidad arquitectónica y operativa plantea tanto un desafío técnico formidable como una ventaja funcional inigualable para la integración con un sistema LLM. Un *pipeline* RAG tradicional requiere ineludiblemente fragmentar ("chunking") el texto en bloques superpuestos y enviarlos a una base de datos vectorial para su posterior recuperación por similitud matemática.¹⁵ Si se aplicara este enfoque ingenuo y destructivo sobre el Diario de Sesiones del Parlamento de Canarias, se aniquilaría irrevocablemente la asombrosa precisión posicional y gramatical que IntelLiText ha indexado de manera tan meticulosa.¹¹ Por el contrario, aprovechar un sistema de traducción Text-to-SQL permitiría al modelo de lenguaje identificar un bloque de oraciones mediante restricciones lingüísticas rigurosas emanadas directamente de la intención del usuario y, posteriormente, utilizar los punteros de *bytes offsets* para recuperar el texto prístino, conformando un sustrato de información perfecto, incontrovertible y matemáticamente exacto para la posterior fase de generación argumentativa.

Limitaciones Epistemológicas y Estructurales de la Generación Aumentada Vectorial (VectorRAG)

El enfoque dominante y omnipresente en los sistemas modernos de Respuesta a Preguntas de Libro Abierto (Open-Book Question Answering) es el denominado VectorRAG.⁵ Este mecanismo procesa los corpus documentales, los convierte en representaciones numéricas multidimensionales continuas (incrustaciones vectoriales densas o *embeddings*) utilizando modelos de codificación neuronal profunda, y recupera los fragmentos de texto en tiempo de inferencia calculando la similitud del coseno o la distancia euclidiana entre el vector representativo de la pregunta del usuario y los vectores de los fragmentos del documento.⁴ Sin

embargo, la investigación académica contemporánea ha demostrado de forma concluyente que la recuperación puramente basada en similitud semántica adolece de carencias severas y falencias estructurales, particularmente en contextos profesionales que demandan análisis formal estricto e interrogaciones agregativas masivas.⁴

En primer término, los sistemas de recuperación basados en vectores muestran dificultades crónicas para capturar la terminología específica de dominio y fallan sistemáticamente al intentar respetar restricciones léxico-estructurales estrictas.⁵ Si un analista político, lingüista o periodista desea conocer las intervenciones exactas donde se utiliza el patrón sintáctico "sustantivo abstracto + adjetivo peyorativo" para referirse a la política fiscal en un periodo temporal concreto, un modelo vectorial puro es matemáticamente incapaz de procesar reglas gramaticales explícitas; el algoritmo simplemente buscará una proximidad semántica global en el espacio latente, ignorando el orden de las palabras, la morfología y las dependencias sintácticas.⁴ Esto invalida el propósito fundamental de herramientas como DISECAN.

En segundo término, VectorRAG fracasa de manera catastrófica ante las denominadas consultas agregativas. Las consultas agregativas requieren recopilar de forma exhaustiva y razonar sobre un gran conjunto de documentos dispersos simultáneamente (por ejemplo, "¿Cuál fue la evolución cuantitativa y cualitativa de la postura de un partido específico sobre el modelo turístico a lo largo de todas las sesiones de la legislatura de 2023?").⁵ El rendimiento del RAG clásico se degrada exponencialmente en estos escenarios debido a múltiples barreras arquitectónicas inherentes⁷:

La completitud y la sensibilidad a la recuperación representan el primer obstáculo insalvable. Fallar en recuperar una sola pieza clave de evidencia documental en un análisis agregativo o estadístico puede llevar a una respuesta generada profundamente incorrecta, sesgada o incompleta. En VectorRAG, esto es un riesgo operativo constante y estadísticamente probable debido a la dependencia topológica del espacio latente, donde intervenciones con un vocabulario atípico pueden quedar aisladas de la consulta principal y nunca ser recuperadas. La restricción del tamaño del contexto (Bounded Context Size) impone el segundo límite físico fundamental. Dado que la ventana de contexto de procesamiento de un LLM posee un presupuesto estricto, finito y económicamente costoso de *tokens*, los sistemas RAG tradicionales de la industria imponen un hiperparámetro estático, frecuentemente denotado

como K , que define el número máximo de fragmentos a recuperar de la base de datos vectorial. Cualquier pregunta analítica que requiera integrar información factual diseminada en

un número de fuentes superior a este límite K no puede ser completamente abordada ni analizada por el modelo, resultando en respuestas truncadas y analíticamente defectuosas.⁵

Finalmente, la pérdida irreversible de la contextualización a largo alcance (Long-range Contextualization) socava la integridad del documento. Las estrategias estándar que dependen del truncamiento o "chunking" ingenuo basado en la longitud de caracteres fragmentan brutalmente los informes estructurales, las argumentaciones retóricas extensas y las intervenciones parlamentarias hilvanadas, diluyendo el sentido semántico original, separando las premisas de sus conclusiones lógicas y destruyendo el contexto histórico que un analista político necesita preservar.⁵

A la luz de estas deficiencias demostradas empíricamente, la migración o re-indexación del Diario de Sesiones del Parlamento de Canarias mediante una base de datos vectorial genérica representaría un retroceso inaceptable respecto a las funcionalidades deterministas que DISECAN y la tecnología IntelLiText ya ofrecen con éxito. Sacrificar el rigor metodológico del análisis del discurso a cambio de una fluidez lingüística superficial desvirtuaría la utilidad científica de la herramienta. Es precisamente en este punto de inflexión donde se hace absolutamente indispensable el salto cualitativo hacia las arquitecturas híbridas estructuradas.⁴

Hacia un Paradigma Estructurado: Structured RAG (S-RAG) y la Traducción a Lenguajes Formales

La necesidad imperiosa de superar las barreras estructurales del RAG tradicional ha impulsado el desarrollo conceptual y práctico del *Structured Retrieval-Augmented Generation* (S-RAG). Investigaciones recientes en el ámbito de la inteligencia artificial y el procesamiento del lenguaje natural sostienen que la inyección sistemática de metadatos estructurados (tales como temas categorizados, análisis de sentimientos, categorías gramaticales precisas y relaciones de grafos de conocimiento) tanto en la consulta del usuario como en los fragmentos de texto almacenados, desplaza el peso de la recuperación desde la mera similitud de representaciones hacia una alineación estructural, relacional y pragmática profunda.⁴ Este avance paradigmático ha demostrado mejorar significativamente el rendimiento algorítmico en preguntas analíticas, comparativas y predictivas, incrementando las métricas de éxito en más de un 30% con un grado de significancia estadística inapelable.⁴

El marco conceptual del S-RAG aborda directamente la problemática intrincada de las consultas agregativas y episódicas transformando el enfoque de recuperación estocástica no estructurada en un problema determinista de consulta formal de bases de datos.⁶ El flujo de trabajo completo de un sistema S-RAG opera sistemáticamente en dos fases macroscópicas bien diferenciadas: la fase de ingestión (*ingestion phase*) y la fase de inferencia (*inference phase*).⁵

Durante el transcurso de la fase de ingestión, operada de manera offline, el sistema S-RAG asume como premisa que cada documento alojado en el corpus representa una instancia de una entidad común subyacente y, por consiguiente, los documentos comparten atributos de contenido recurrentes que pueden ser formalizados. Mediante técnicas de predicción de esquemas iterativas impulsadas por LLMs, el sistema deduce una estructura relacional óptima, empareja iterativamente el texto desestructurado de los documentos con dicho esquema, extrae los valores normalizados y puebla finalmente una base de datos tabular relacional que actúa como un gemelo digital estructurado del corpus.⁵ En el contexto específico del buscador DISECAN, esta fase analítica de ingestión y estructuración profunda ya se encuentra materializada y depurada gracias al monumental trabajo informático previo de segmentación gramatical, indexación léxica y mapeo relacional implementado en la arquitectura IntelLiText y almacenado en MySQL.¹²

En la fase dinámica de inferencia del sistema S-RAG, la consulta formulada en lenguaje natural

por el usuario final (denotada matemáticamente como q) es capturada y traducida de forma automatizada mediante un agente LLM hacia un lenguaje de consulta formal e interpretable por máquinas, siendo el lenguaje estructurado de consultas (SQL) el estándar de facto para este propósito (paradigma *Text-to-SQL*).⁵ Al interactuar directa y sintácticamente con la base de datos relacional, el sistema S-RAG sorteja con elegancia el límite asfixiante del hiperparámetro K . Es el propio motor SQL —con sus algoritmos de indexación b-tree hiper-optimizados— el encargado de realizar agregaciones, agrupamientos, filtrados por rangos de fecha y condicionamientos lógicos masivos de forma casi instantánea y exhaustivamente completa, retornando únicamente aquellos registros que cumplen el criterio condicional absoluto estipulado por el investigador.¹³

No obstante, a pesar de la inmensa superioridad del S-RAG para consultas cuantitativas directas (por ejemplo, contar el número exacto de intervenciones de un político), cuando la respuesta final a la consulta no puede ser resuelta simplemente devolviendo un valor escalar, un promedio matemático o una lista tabulada plana desde la base de datos, el enfoque S-RAG puro revela sus propias insuficiencias pragmáticas.¹³ Si un periodista interroga al sistema sobre "¿De qué manera evolucionó argumentativamente el tono de las respuestas parlamentarias respecto a la crisis migratoria durante el último debate del estado de la nacionalidad?", el retorno de una tabla SQL resulta ilegible e inservible para el razonamiento narrativo humano. Surge entonces, como cúspide evolutiva de esta tecnología, la variante metodológica avanzada conocida como **Hybrid-S-RAG**.⁵

El Patrón Arquitectónico Hybrid-S-RAG: Simbiosis de Precisión Relacional y Generación Semántica

El patrón arquitectónico Hybrid-S-RAG representa la simbiosis operativa perfecta entre la inquebrantable precisión estructurada de las bases de datos relacionales y el portentoso procesamiento semántico, inferencial y generativo de los LLMs modernos. Esta arquitectura no fuerza una elección dicotómica entre SQL y RAG, sino que los dispone en un flujo secuencial donde las fortalezas de uno anulan sistemáticamente las debilidades del otro. Opera metodológicamente en dos pasos secuenciales de inferencia que maximizan las virtudes de ambos ecosistemas computacionales⁵:

El primer paso fundamental es la **Traducción Formal y el Filtrado Estructural Asistido (Dominio S-RAG)**. El sistema capta la consulta en lenguaje natural y moviliza un agente especializado para generar una sentencia SQL sintácticamente válida. Sin embargo, el matiz crucial aquí radica en que, en lugar de intentar forzar al SQL a extraer directamente la respuesta analítica o el resumen final, la ejecución del comando SQL sobre la base de datos se diseña para devolver un conjunto acotado, exhaustivo y altamente relevante de identificadores de documentos, punteros de memoria o fragmentos físicos.⁵ En la integración proyectada para DISECAN, esta operación de filtrado maestro equivaldría a retornar de la base de datos MySQL una lista depurada de `IDSentence` acompañada de sus respectivos metadatos de acceso físico a bajo nivel (los `starting bytes` y `byte sizes`) correspondientes a las intervenciones que

superaron el tamiz léxico.¹²

El segundo paso crítico es la **Extracción de Evidencia y Generación basada en el Sub-corpus (Dominio VectorRAG / LLM Generation)**. El conjunto de punteros filtrado en la fase anterior actúa como los cimientos de un sub-corpus altamente concentrado y empíricamente validado. Sobre este dominio drásticamente reducido y descontaminado de ruido irrelevante, el sistema está en disposición de ensamblar los textos completos de los párrafos pertinentes y suministrarlos en bloque a un LLM avanzado como contexto textual infalible.⁵ Si el volumen del sub-corpus excede marginalmente la ventana de contexto, es exclusivamente en esta etapa tardía donde se aplicaría una técnica de vectorización efímera y recuperación clásica, buscando dentro de un universo de datos que ya ha sido certificado como cronológica, autoral y gramaticalmente correcto.⁷

El despliegue de un sistema híbrido secuencial en el flujo de trabajo Text-to-SQL y RAG resuelve simultáneamente y de raíz el déficit crónico de contextualización semántica que adolecen las bases de datos relacionales puras, y la peligrosa miopía léxico-estructural y propensión a la alucinación que caracteriza a los motores de búsqueda vectoriales aislados.¹⁸ Se establece así una tubería de procesamiento (pipeline) donde el determinismo precede siempre a la probabilidad estadística.

Propuesta Metodológica Exhaustiva para la Implementación en el TFT

La formulación técnica y el desarrollo práctico de un Trabajo de Fin de Título centrado en la unificación algorítmica del buscador lingüístico DISECAN con las capacidades cognitivas de las arquitecturas RAG demandan el diseño de un flujo de operaciones meticulosamente orquestado. El sistema debe ser capaz de interpretar la ambigüedad inherente de la intención del usuario político o periodista, transformar esa intención estocástica en sentencias MySQL deterministas, complejas y específicas de IntelLiText, manejar los punteros a nivel de sistema operativo para acceder a los archivos .txt y levantar la información física, inyectarla en un contexto efímero de inteligencia artificial, y finalmente sintetizar una respuesta lingüísticamente fundada, coherente y argumentativa.⁸

La metodología arquitectónica y de software propuesta para el TFT se desglosa lógicamente en cinco fases operacionales críticas y secuenciales:

Fase 1: Comprensión Semántica de la Consulta y Módulo de Traducción Text-to-SQL

La primera etapa del procesamiento sistémico consiste en la ingesta y decodificación de la entrada en lenguaje natural proporcionada por el usuario. Se requiere el despliegue de un agente LLM configurado explícitamente para el modelado y la inferencia *Text-to-SQL*.¹⁵ Dado que la complejidad computacional de generar código SQL perfectamente adaptado a un esquema externo de alta especificidad es sumamente alta, se deben implementar técnicas avanzadas de "Ingeniería de Prompts" (Prompt Engineering). Estas técnicas exigen la inyección del Lenguaje de Definición de Datos (Data Definition Language - DDL) del esquema exacto de

DISECAN directamente en el contexto dinámico (In-Context Learning) del modelo en cada interacción.¹⁵

Este agente traductor debe ser provisto de un conocimiento profundo e inequívoco respecto a que la tabla Sessions contiene los metadatos vertebrales, tales como el identificador del orador y la fecha de intervención, y que el motor IntelLiText subyacente soporta filtros léxicos de extrema complejidad (búsqueda por lemas, categorías POS, comodines posicionales) mediante indexación interna preestablecida.¹² Cuando un analista formula una consulta del tenor: *"Analiza el tono y las implicaciones de las ocasiones en las que el portavoz del partido X utilizó la palabra 'crisis' seguida de un sustantivo económico a una distancia máxima de tres palabras durante el año 2021"*, el agente Text-to-SQL traduce esta intención semántica compleja a una directiva SQL rigurosa. Esta directiva condicionará la tabla de metadatos temporal y autoralmente, e invocará simultáneamente los operadores de distancia léxica y coincidencias de categorías gramaticales soportados por la lógica relacional subyacente de la plataforma.

Para optimizar drásticamente la tasa de éxito en este proceso de traducción formal, investigaciones recientes y análogas en Text-to-SQL multilingüe (como la realizada en la interfaz de consultas híbridas turco-inglés) sugieren y validan fuertemente la implementación de una estrategia de enriquecimiento de datos.²¹ Esta técnica consiste en proporcionar al LLM filas de muestra reales extraídas de la base de datos integradas dentro de las definiciones del esquema en el propio prompt. Esta provisión de ejemplos concretos (Few-Shot Prompting) minimiza espectacularmente el ruido sintáctico, mejora la asertividad estructural de la predicción y previene iteraciones fallidas.²¹ Resulta un paso vital para que el LLM comprenda la naturaleza exacta del formato numérico del identificador de bytes de IntelLiText y cómo se correlacionan biunívocamente las cadenas de texto con las etiquetas de marcado lingüístico almacenadas.

Fase 2: Ejecución Relacional Estricta y Recuperación de Punteros Físicos (Interacción con el Motor DISECAN)

Una vez generada y validada en su sintaxis, la consulta SQL estructurada es despachada telemáticamente al servidor MySQL de 5.6GB que aloja el corazón de DISECAN.¹² Es en esta fase crítica de ejecución donde la arquitectura híbrida demuestra de forma inapelable su abrumadora superioridad algorítmica frente a la mera similitud vectorial. En fracciones de milisegundo, el motor relacional de la base de datos procesa los árboles de indexación b-tree, evalúa matemáticamente las condicionalidades morfosintácticas estrictas exigidas, aplica las constricciones temporales y resuelve la consulta filtrando millones de posibles candidatos.¹² Crucialmente para el diseño del sistema, el resultado de esta fase de procesamiento no es el texto plano de las intervenciones, sino una matriz de datos altamente estructurada. Esta matriz de retorno contiene de manera exclusiva los identificadores únicos IDSentence, y los invaluable atributos posicionales starting byte (el byte de inicio exacto en el disco duro) y byte size (el tamaño total en bytes del bloque de lectura) correspondientes a los párrafos físicos donde ocurren las coincidencias validadas.¹² Esta matriz bidimensional constituye el esqueleto cartográfico y la hoja de ruta infalible del "sub-corpus" documental mencionado en el modelo teórico Hybrid-S-RAG.¹³

Fase 3: Acceso Físico Secuencial a Bajo Nivel y Ensamblaje Estructural del Sub-corpus

Con los metadatos numéricos de posicionamiento en memoria disponibles tras la consulta SQL exitosa, el sistema de software intermedio transita hacia la recolección física del texto en los discos de almacenamiento. Para ello, es imperativo desarrollar un subsistema de E/S (Entrada/Salida) de bajo nivel codificado en el lenguaje de control del servidor (usualmente implementado en Python, apoyándose en bibliotecas nativas compatibles con flujos de compensación de *bytes* o utilidades especializadas como *Stream Reader* que gestionan la decodificación de caracteres a nivel de sistema operativo).¹⁷

Este módulo de extracción ejecuta iterativamente comandos del tipo `seek()` dirigidos sobre los inmensos archivos `paragraphs.txt` (de 257.842 KB) y `sentences.txt` alojados en el servidor.¹² Al saltar directamente a la posición de memoria dictada por el *byte* de inicio y ordenar una lectura de bloque de texto con la longitud exacta delimitada por la variable *byte size*, el sistema evita categóricamente la necesidad de cargar en la memoria RAM ramificada conjuntos masivos de datos irrelevantes, replicando a la perfección el rendimiento óptimo y la eficiencia operativa diseñada originalmente por los investigadores Carreras-Riudavets y Hernández-Figueroa.¹² Los párrafos resultantes de estas operaciones de I/O, que contienen las oraciones objetivo incrustadas de forma natural en su contexto original discursivo, se concatenan sistemáticamente en una estructura de datos transitoria en memoria. Este conjunto textual pristino y purificado representa la verdad terreno inmutable (Grounded Truth) fundamentada léxicamente sobre la cual operará el modelo de lenguaje.

Fase 4: Refinamiento Vectorial Dinámico del Sub-corpus (Fase de Fallback Opcional)

Dependiendo intrínsecamente de la naturaleza y amplitud de la consulta agregativa del usuario, el sub-corpus textual ensamblado al finalizar la Fase 3 podría abarcar apenas unas pocas docenas de párrafos altamente específicos o, en el caso de evaluar términos o conceptos altamente frecuentes a lo largo de toda una legislatura de la actividad parlamentaria canaria, cientos o miles de páginas de transcripciones. Si la longitud acumulada de *tokens* de este sub-corpus excede la capacidad límite de la ventana de contexto del LLM generador asignado (manifestando el problema del Bounded Context Size), la arquitectura debe implementar de forma automática un segundo filtro de compresión de información, alineándose así plenamente con las especificaciones del estándar Hybrid-S-RAG.⁷

Sobre este sub-corpus dinámico y expansivo recién extraído del disco, se procedería a instanciar en tiempo real una base de datos vectorial efímera (utilizando tecnologías robustas de vectorización en memoria como ChromaDB o bases de datos columnares como LanceDB).⁸ El texto filtrado se dividiría metódicamente en fragmentos semánticos superpuestos, se invocaría un modelo de codificación (*embedding model*) para generar la representación vectorial, y se aplicaría un filtrado semántico estricto basado en similitud cosenoidal contra la consulta original.¹³

A diferencia diametral de lo que ocurre en el diseño de un RAG puro inicial —donde la vectorización masiva diluye la precisión—, el uso de búsqueda vectorial en esta fase secundaria de *fallback* es extremadamente seguro y metodológicamente robusto: dado que la población documental sobre la que se busca similitud ya ha sido pre-filtrada algorítmicamente por estrictas restricciones de metadatos precisos, límites temporales exactos y requisitos formales categóricos (posiciones POS, distancias de palabras), se elimina de raíz la inclusión inadvertida de intervenciones de otras épocas, o de oradores que utilizaran vocablos semánticamente próximos pero léxica e institucionalmente irrelevantes para la tesis de investigación.¹⁵ El resultado final es un destilado de información puro, semánticamente relevante y posicionalmente comprobado.

Fase 5: Ensamblaje del Contexto, Generación Aumentada y Atribución Bibliográfica

La fase culminante e interactiva de la metodología reside en la síntesis generativa de la respuesta analítica. El LLM encargado de la interacción con el usuario recibe un *prompt* enriquecido y meticulosamente estructurado que combina la pregunta original formulada con el bloque consolidado y refinado de párrafos documentales provenientes del flujo DISECAN.¹⁸ Mediante ingeniería de instrucciones, se instruye explícitamente y con alta penalización por desvío al modelo para que adopte un enfoque extractivo y fundamentado (estilo de respuesta Archivist o de Periodismo de Datos Estricto).⁸ En este paradigma de generación, el LLM debe elaborar una respuesta analítica que conecte de manera holística la narrativa política identificada, razonando sobre el discurso, pero apoyando ineludiblemente cada aseveración interpretativa mediante una cita textual directa extraída del contexto proveído.

Puesto que el sistema arquitectónico ha mantenido inalterada la trazabilidad end-to-end del IDSession, el nombre del orador, la fecha de la sesión parlamentaria y la ubicación física exacta del texto dentro del documento matriz¹², el LLM posee la capacidad y el mandato de incluir anotaciones bibliográficas enriquecidas, referencias institucionales y pies de página exactos en su salida final generada.⁸ El resultado tangible de este proceso es una investigación cualitativa profunda que no sufre en absoluto de alucinaciones (las perjudiciales invenciones autónomas de datos por parte del modelo), ya que el sustrato informativo de la red neuronal está fuertemente constreñido, gobernado y auditado por el universo cerrado y estructurado que arrojó la base de datos SQL del IATEX.

Estrategias de Evaluación, Calibración Cuantitativa y Resolución de Problemas de Ingeniería

La implementación práctica de este sofisticado puente de software entre la tecnología propietaria IntelLiText y las canalizaciones modernas de orquestación de IA (como LangChain o LlamaIndex, orquestadores habituales de LLM y arquitecturas RAG avanzadas) suscita inevitablemente varios escollos de ingeniería e impone la necesidad de protocolos de evaluación estrictos.

Para medir empíricamente el éxito del sistema desarrollado durante la ejecución del TFT, resulta

metodológicamente inaceptable e inadecuado basarse meramente en la percepción subjetiva humana sobre la fluidez o calidad aparente de la respuesta narrativa generada.¹ Deben establecerse y documentarse métricas cuantitativas reproducibles que analicen de forma aislada la robustez matemática del puente Text-to-SQL y la integridad factual del proceso RAG de recuperación.²⁴

Métrica de Evaluación del Sistema	Objetivo Analítico	Parámetro de Éxito y Metodología
Execution Accuracy (EX) del Text-to-SQL	Medir en qué porcentaje de ocasiones el LLM logra predecir el esquema y las reglas lógicas para producir un SQL sintácticamente válido que se ejecute en MySQL sin lanzar errores de compilación o violaciones de formato.	Investigaciones recientes con estrategias híbridas y <i>few-shot</i> logran alcanzar valores de EX superiores a 0.78, un incremento del 11% frente a rendimientos base sin necesidad de <i>fine-tuning</i> . ²¹
Groundedness (Fundamentación de RAGAS)	Cuantificar matemáticamente en qué medida la respuesta generada se deriva de forma estricta y exclusiva de los fragmentos textuales obtenidos de DISECAN, castigando severamente la intrusión de conocimientos externos pre-entrenados en el LLM.	Utilizando LLMs como jueces, un sistema RAG híbrido bien ajustado debe superar consistentemente el valor umbral de 0.8 en una escala de 0.0 a 1.0. Prompts más estrictos incrementan este valor. ¹⁵
Context Relevance (Relevancia del Contexto)	Medir la densidad de información útil (ratio señal-ruido) dentro del texto final recuperado. Valida si la fase de <i>byte offset</i> combinada con un posible filtrado vectorial ha capturado la porción documental pertinente sin contaminar la memoria del	Umbral superior a 0.8. Una puntuación baja indicaría problemas graves en las lógicas de <i>chunking</i> dinámico o fallos en el <i>seek</i> físico. ¹⁵

	modelo.	
Answer Relevance (Relevancia de la Respuesta)	Valorar heurísticamente hasta qué punto la contestación generada aborda directamente la formulación semántica del usuario, ponderando la utilidad final de la herramienta en un flujo real de investigación periodística o sociológica.	Evalúa la capacidad del LLM generador final. Si es baja pero el contexto era adecuado, el problema radica en la inferencia del modelo generativo, no en la recuperación. ¹⁵

Se anticipa teóricamente que la inclusión mandatoria del componente estructurado SRAG establezca y potencie exponencialmente el rendimiento global del sistema evaluado, disminuyendo dramáticamente los peligrosos riesgos de cola (*tail risk*) presentes en la mayoría de implementaciones LLM genéricas. Estos riesgos se refieren a escenarios extremos en los que las respuestas colapsan por completo debido a recuperaciones episódicas nulas, sesgadas o gravemente distorsionadas, un fenómeno que la infraestructura Text-to-SQL anula por diseño.⁴

Adicionalmente, durante el diseño del prototipo para el TFT, es perentorio abordar los problemas técnicos directos vinculados a la escalabilidad de la arquitectura propuesta. La arquitectura Text-to-SQL requiere modelos LLM sumamente competentes en lógica de programación, generación de código y seguimiento de instrucciones algorítmicas.¹⁵ No es operativamente factible emplear modelos fundamentales de pequeña escala u *open-source* básicos sin la aplicación de metodologías de ajustes finos intensivos (*fine-tuning*), lo cual supondría una barrera de recursos económicos y de tiempo de cómputo inasumible para la mayoría de investigaciones académicas convencionales.¹ Sin embargo, la inclusión empírica del esquema de tabla y de relaciones DDL detalladas en la directriz sistémica inicial facilita enormemente la generalización en contexto (*In-Context Generalization*), permitiendo aprovechar modelos de frontera disponibles comercialmente a bajo coste por *token* y eludiendo la tediosa obligación del re-entrenamiento local.⁴

Otro aspecto operativo insoslayable se halla en el procesamiento de la codificación de caracteres y el manejo físico del disco duro al manipular el backend del sistema DISECAN. Archivos de proporciones colosales como paragraphs.txt exigen rigurosamente que los módulos de búsqueda por desplazamiento de Python o C++ gestionen el formato de *bytes* de forma estricta (usualmente asumiendo y forzando arquitecturas de codificación UTF-8 para evitar corrupciones de lectura en caracteres hispanos acentuados) y manejen eficientemente el buffer de lectura de un flujo asíncrono para mantener los tiempos de respuesta exigidos en aplicaciones web interactivas modernas.¹²

Implicaciones Éticas, Periodísticas y Analíticas en el

Estudio del Discurso Institucional

La profunda justificación teórica y práctica subyacente para el desarrollo, inversión e implementación de este sistema híbrido en el contexto de un TFT, o como un proyecto de extensión tecnológica del IATEXT, se arraiga indiscutiblemente en las necesidades apremiantes de las Ciencias Sociales y las Humanidades Digitales (SSH) contemporáneas.² Los repositorios institucionales, las bibliotecas patrimoniales y, muy especialmente, los diarios de sesiones parlamentarias contienen narrativas sociales de inmensa complejidad, repletas de matices, e interdependientes en su contexto temporal. En estos entornos, el rigor semántico, la precisión morfológica y la fidelidad documental son valores científicos y democráticos insoslayables.² El uso irrestricto de Herramientas de Inteligencia Artificial (IA) generativas de propósito general y cajas negras algorítmicas en salas de redacción periodística, universidades e institutos de investigación (como en el análisis histórico de periódicos o las plataformas especializadas de Humanidades Digitales análogas a "The Conversation", "Canarias Azul" o el "Buscador ModeCan") genera un fundamentado y razonable escepticismo entre los profesionales.⁸ La imposibilidad técnica actual de controlar los parámetros del motor de recuperación o de auditar con transparencia total la procedencia exacta de la información inhibe fuertemente su adopción masiva en flujos de trabajo críticos, transformando el noble proceso de recuperación documental en un procedimiento opaco e inescrutable que socava la confianza pública.⁸ La aplicación de la exhaustiva metodología descrita para integrar la tecnología de DISECAN desmantela desde sus cimientos esta opacidad estructural. Al exigir a nivel arquitectónico que el razonamiento estadístico y lingüístico del LLM quede absolutamente subordinado y rígidamente parametrizado por una consulta base Text-to-SQL —la cual es dictaminada sistemáticamente contra un repositorio léxico determinista y verificado humanamente—, el sistema adquiere una dimensión de total transparencia y auditabilidad.⁸ El usuario investigador o el periodista de datos puede, en cualquier momento, examinar la sentencia SQL exacta generada de forma intermedia, constatando sin asomo de duda ni sombra de sospecha qué parámetros temporales, de autoría política, combinaciones morfosintácticas estrictas o flexiones de lemas se han extraído efectivamente del disco para fundamentar la inferencia y la respuesta final del sistema.¹⁰

Este incomparable nivel de control lexicológico permite a la comunidad investigadora realizar aproximaciones cualitativas y analíticas inéditas al corpus del discurso político de la Comunidad Autónoma de Canarias. Un sociólogo investigador podría emplear la fluida interfaz conversacional de la herramienta híbrida para identificar e investigar mutaciones discursivas sutiles e insidiosas —como, por ejemplo, el cambio progresivo a lo largo de las décadas en el uso de adjetivos peyorativos asociados a debates sobre la "cohesión europea" o el estado de bienestar—. Esta integración permitiría que el módulo RAG estructure, argumente y redacte un ensayo académico resumiendo el fenómeno histórico y sus implicaciones retóricas, mientras el componente relacional SQL subyacente asegura, con precisión matemática, la base fáctica de la progresión temporal, la autoría institucional y la exactitud posicional de cada cita textual.¹²

Conclusiones Metodológicas

La investigación teórica y la propuesta de diseño para la consolidación de un sistema informático que entrelace, de forma sinérgica e inseparable, la minería de texto estructural determinista y los modelos de IA generativa de vanguardia, representa una contribución de incalculable valor metodológico a la técnica analítica textual contemporánea aplicada al ámbito gubernamental e institucional. La propuesta estructural para cimentar este TFT debe fundamentarse sobre la tesis científica irrefutable de que la recuperación basada en vectores de incrustación aislada es una tecnología crónicamente inmadura e insuficiente frente a interrogaciones léxicas especializadas que demandan cálculo de distancias morfológicas exactas, condicionantes metadatos estrictos y la resolución de preguntas agregativas a escala poblacional masiva.⁴

La metodología híbrida exhaustivamente detallada erige una pasarela de transferencia de conocimiento bidireccional de última generación. En el flujo descendente de información, la inmensa versatilidad lingüística, semántica y sintáctica del usuario humano se condensa e interpreta sistemáticamente mediante tecnologías avanzadas de Text-to-SQL. Estas intenciones se transmutan en sentencias transaccionales inequívocas y rígidas, capaces de explotar con extrema eficiencia la arquitectura optimizada por el IATEX en el núcleo de DISECAN y su deslumbrante motor IntelLiText.¹¹ Esta operación de descenso aprovecha de forma quirúrgica la indización determinista basada en *byte offsets* de la tabla central MySQL y los enormes ficheros planos de almacenamiento de párrafos y sentencias que garantizan un acceso al disco sin precedentes.¹²

En contraposición complementaria, en el flujo ascendente de síntesis, el paradigma Hybrid-S-RAG orquesta la vasta información cruda extraída a nivel lógico, posicional y léxico. El sistema reduce el ruido documental a un sub-corpus puro, empíricamente validado, sobre el que puede aplicarse una delgada capa vectorial de rescate si fuera estrictamente preciso por limitaciones de memoria. El ciclo culmina ineludiblemente en la generación de una narrativa humanizada, inmersiva, retóricamente impecable y, por diseño estructural, totalmente libre de alucinaciones contextuales.¹³

Implementar y perfeccionar este revolucionario ecosistema computacional de control léxico-estructural profundo, íntimamente emparejado con la vasta comprensión semántica de un LLM de frontera, convertirá indiscutiblemente al histórico buscador DISECAN no solo en un eficiente pero pasivo sistema de consultas para la investigación lingüística clásica, sino en un pionero asistente virtual sociopolítico y analítico activo. El desarrollo de este TFT cristalizará en un instrumento científico capaz de comprender, agregar, sintetizar, contrastar y exponer el complejo discurso institucional del Parlamento de Canarias con una fiabilidad estadística y una exactitud bibliográfica que resultan inalcanzables para las soluciones algorítmicas que ofrece el mercado corporativo genérico actual.⁸ Con la consecución de este modelo arquitectónico, se establece un paradigma tecnológico universal y transferible para cualquier instituto de Humanidades Digitales y centro de lingüística de corpus que persiga el noble y ambicioso objetivo de proyectar y potenciar la vigencia de sus infraestructuras relacionales clásicas en la

inminente era de los modelos cognitivos masivos.²

Obras citadas

1. Topic-RAG for historical newspapers: Enhancing information retrieval in humanities research through topic-based retrieval-augmented generation | Computational Humanities Research - Cambridge University Press & Assessment, fecha de acceso: junio 9, 2026, <https://www.cambridge.org/core/journals/computational-humanities-research/article/topicrag-for-historical-newspapers-enhancing-information-retrieval-in-humanities-research-through-topicbased-retrievalaugmented-generation/054E6DA3416EA982F61858B30E7CAB6D>
2. Proceedings of Shaping Multilingual, Multimodal AI for the Social Sciences and Humanities (LLMs4SSH) @ LREC 2026, fecha de acceso: junio 9, 2026, <http://lrec-conf.org/proceedings/lrec2026/workshops/lms4ssh/2026.lms4ssh-1.0.pdf>
3. Proceedings of the 5th International Conference on Natural Language Processing for Digital Humanities - ACL Anthology, fecha de acceso: junio 9, 2026, <https://aclanthology.org/volumes/2025.nlp4dh-1/>
4. SRAG: RAG with Structured Data Improves Vector Retrieval - arXiv, fecha de acceso: junio 9, 2026, <https://arxiv.org/html/2603.26670v1>
5. Structured RAG for Answering Aggregative Questions - arXiv, fecha de acceso: junio 9, 2026, <https://arxiv.org/html/2511.08505v1>
6. Structured RAG for Answering Aggregative Questions - OpenReview, fecha de acceso: junio 9, 2026, <https://openreview.net/forum?id=jH6K80njJA>
7. (PDF) Structured RAG for Answering Aggregative Questions - ResearchGate, fecha de acceso: junio 9, 2026, https://www.researchgate.net/publication/397522348_Structured_RAG_for_Answering_Aggregative_Questions
8. Can AI Help Journalists Think? Exploring RAG Systems for Newsroom Applications, fecha de acceso: junio 9, 2026, <https://atrium-research.eu/blog/can-ai-help-journalists-think-exploring-rag-systems-for-newsroom-applications/>
9. IATEX - ULPGC, fecha de acceso: junio 9, 2026, <https://iatext.ulpgc.es/en>
10. DiSeCan Buscador IL-TIP - ULPGC, fecha de acceso: junio 9, 2026, <https://appstip.iatext.ulpgc.es/disecan/>
11. Applications of Digital Humanities: Textual Search Engines IA - IATEX, fecha de acceso: junio 9, 2026, <https://iatext.ulpgc.es/en/aplicaciones/buscador-textual>
12. DiSeCan: A tool for consulting parliamentary sessions ... - accedaCRIS, fecha de acceso: junio 9, 2026, <https://accedacris.ulpgc.es/bitstream/10553/136356/1/DiSeCan.pdf>
13. STRUCTURED RAG FOR ANSWERING ... - OpenReview, fecha de acceso: junio 9, 2026, <https://openreview.net/pdf/378ae1b855654b1fc2493fea44aba31e6cba38f3.pdf>
14. Large Language Models for Oral History Understanding with Text Classification

- and Sentiment Analysis - arXiv, fecha de acceso: junio 9, 2026, <https://arxiv.org/html/2508.06729v1>
15. Building AI Applications with Snowflake Cortex: RAG, Text-to-SQL & CoCo, fecha de acceso: junio 9, 2026, <https://www.snowflake.com/en/developers/guides/accelerate-app-dev-coco/>
 16. Lance Blob V2: Making Multimodal Data a First-Class Citizen in the Lakehouse - LanceDB, fecha de acceso: junio 9, 2026, <https://www.lancedb.com/blog/lance-blob-v2>
 17. Algorithms — list of Rust libraries/crates // Lib.rs, fecha de acceso: junio 9, 2026, <https://lib.rs/algorithms>
 18. Database Interaction Techniques: Text-to-SQL, RAG, and Hybrid Search | by Amit Dhiman, fecha de acceso: junio 9, 2026, <https://medium.com/@amitdhiman91/database-interaction-techniques-text-to-sql-rag-and-hybrid-search-70c6029040c4>
 19. [2511.08505] Structured RAG for Answering Aggregative Questions - arXiv, fecha de acceso: junio 9, 2026, <https://arxiv.org/abs/2511.08505>
 20. Aplicaciones de Humanidades Digitales | Instituto Universitario de Análisis y Aplicaciones Textuales - IATEXT, fecha de acceso: junio 9, 2026, <https://iatext.ulpgc.es/es/aplicaciones>
 21. Schema Retrieval with Embeddings and Vector Stores Using Retrieval-Augmented Generation and LLM-Based SQL Query Generation - MDPI, fecha de acceso: junio 9, 2026, <https://www.mdpi.com/2076-3417/16/2/586>
 22. End-to-End Text-to-SQL with Dataset Selection: Leveraging LLMs for Adaptive Query Generation - arXiv, fecha de acceso: junio 9, 2026, <https://arxiv.org/html/2508.06387v2>
 23. Filtering in Vector Search with Metadata and RAG Pipelines - Turso, fecha de acceso: junio 9, 2026, <https://turso.tech/blog/filtering-in-vector-search-with-metadata-and-rag-pipelines>
 24. Building Secure Structured RAG with Bedrock and Redshift: Mastering Text-to-SQL and the Full RAG Toolkit | AWS Builder Center, fecha de acceso: junio 9, 2026, <https://builder.aws.com/content/36SsTqrCLdSlufZbDyp4QvAuT/building-secure-structured-rag-with-bedrock-and-redshift-mastering-text-to-sql-and-the-full-rag-toolkit>
 25. IATEXT - ULPGC, fecha de acceso: junio 9, 2026, <https://iatext.ulpgc.es/es>